



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ Информатика и системы управления (ИУ) _____

КАФЕДРА _____ «Теоретическая информатика и компьютерные технологии» (ИУ-9) _____

ОТЧЕТ ПО ПРОИЗВОДСТВЕННОЙ ПРАКТИКЕ

Студент _____ Ильичев Андрей Сергеевич _____

фамилия, имя, отчество

Группа _____ ИУ9-21М _____

Тип практики _____ Производственная _____

Название

предприятия _____

Студент

подпись, дата

фамилия, и.о.

Руководитель практики

подпись, дата

фамилия, и.о.

Оценка _____

Оглавление

Введение	3
Данные и разбиения	4
Базовая модель и метрики	5
Метод активного обучения	6
Экспериментальная постановка: «gold → noisy → восстановление»	7
Результаты и анализ	8
Заключение	14
Список использованных источников.....	15

Введение

Тема данной работы — активное обучение (Active Learning) для сегментации купероза на изображениях лица.

Цель работы — показать эффективность Active Learning для задачи бинарной сегментации купероза, то есть продемонстрировать, что при итеративном отборе наиболее информативных изображений (например, по критерию неопределённости предсказаний модели) и последующем расширении обучающей выборки можно улучшать качество модели. В рамках работы реализуется цикл активного обучения: обучение модели на начальном наборе размеченных данных, оценка неопределённости на пуле неразмеченных изображений, выбор подмножества для уточнения разметки и повторное дообучение с последующей оценкой качества по метрикам сегментации.

Данные и разбиения

Описание набора данных

В работе используется датасет изображений лица с разметкой областей купероза (розацеа) в задаче бинарной сегментации. Данные организованы в виде четырёх частей:

- **train** — обучающая выборка (в текущей версии проекта содержит 305 изображений), используется для обучения моделей и проведения экспериментов с активным обучением.
- **val** — валидационная выборка, используется для подбора гиперпараметров, выбора лучшей эпохи и early stopping.
- **test_rf** — тестовая выборка из источника Roboflow, используется только для итоговой оценки качества на домене Roboflow.
- **test_cvat** — тестовая выборка из источника CVAT, также не участвует в обучении.

Каждая часть (train/val/test_rf/test_cvat) имеет одинаковую структуру:

- папка images/ с изображениями,
- файл аннотаций annotations.coco.

Формат аннотаций (COCO)

Разметка хранится в формате COCO Segmentation. В COCO-файле содержатся:

- список изображений (images) с полями id, file_name, width, height;
- список аннотаций (annotations), где каждая аннотация содержит image_id и описание области в поле segmentation.

Поле segmentation может быть задано:

- полигональной разметкой (список полигонов),
- либо **RLE-представлением** (run-length encoding).

В рамках бинарной сегментации купероза все полигоны/области для одного изображения объединяются в **одну бинарную маску** (0 — фон, 1 — купероз), которая затем приводится к размеру входа модели.

Формирование L/U для активного обучения

Для экспериментов с активным обучением (Active Learning, AL) используется обучающая часть train. На её основе формируются два поднабора: L (labeled) — начальный размеченный набор, на котором обучается стартовая модель, и U (unlabeled pool) — пул изображений, считающихся «неразмеченными» до момента их отбора на итерации AL. В рамках схемы 2 train делится на L0 и U0 в пропорции $L0 \approx 30\%$ и $U0 \approx 70\%$. Далее на каждой итерации AL из U выбирается K изображений (в данной работе $K=20$) по критерию неопределённости модели. Выбранные изображения переводятся из U в L: для них «раскрывается» gold-разметка (в реальном сценарии это ручная разметка специалистом, в эксперименте — доступ к эталонной разметке в датасете).

Воспроизводимость и фиксирование seed

Для воспроизводимости экспериментов фиксируется псевдослучайное зерно ($seed=0$). Разбиение $train \rightarrow (L0, U0)$ формируется детерминированно: список идентификаторов изображений перемешивается с использованием генератора, инициализированного фиксированным seed, после чего первые $|L0|$ изображений составляют L0, остальные — U0. Фиксация seed позволяет повторно получить идентичные L0/U0 и сопоставимые результаты между запусками, что важно для корректного анализа динамики качества по итерациям AL.

Базовая модель и метрики

Базовая модель сегментации

В качестве модели для активного обучения используется SegFormer-B5 — архитектура семантической сегментации на основе трансформерного энкодера MiT (Mix Transformer) и лёгкого MLP-декодера. Модель инициализируется весами из прошлой НИР и дообучается на данных задачи бинарной сегментации (1 класс). Для стабилизации обучения на ограниченной GPU-памяти применяется смешанная точность (AMP) и градиентная аккумуляция.

Метрики качества

Качество сегментации оценивается метриками Dice и IoU. Dice (коэффициент Сёренсена—Дайса) измеряет степень перекрытия предсказанной маски и эталонной маски и хорошо подходит для задач с несбалансированными классами (когда область объекта существенно меньше фона). IoU (Intersection over Union) также характеризует перекрытие масок и часто используется как дополнительная метрика. Для бинаризации вероятностной карты используется порог 0.5 ($\text{sigmoid}(\text{logits}) > 0.5$).

Особенности обучения на GPU

В экспериментах используется размер входа 256×256 . Обучение выполняется с `TRAIN_BATCH_SIZE=2` и `ACCUM_STEPS=2` (эффективный `batch=4`) при включённой AMP, что позволяет уменьшить потребление видеопамати и ускорить вычисления.

Метод активного обучения

Итеративная схема

Используется итеративный цикл Active Learning: (1) обучение модели на текущем размеченном наборе L ; (2) оценка неопределённости на пуле U ; (3) выбор K наиболее информативных примеров; (4) добавление выбранных примеров в L и дообучение модели. Итерации повторяются до достижения заданного числа шагов.

Оценка неопределённости (uncertainty sampling)

Для отбора изображений применяется стратегия uncertainty sampling. Модель выдаёт вероятности $p(x)$ для каждого пикселя. Определяется доля «уверенных» пикселей `confident_ratio`: пиксели считаются уверенно отнесёнными к классу купероза, если $p \geq \text{pos_thr}$, и уверенно отнесёнными к фону, если $p \leq \text{neg_thr}$. В работе используются пороги `pos_thr=0.90` и `neg_thr=0.10`. Итоговая неопределённость изображения задаётся как $\text{uncertainty} = 1 - \text{confident_ratio}$. На

каждой итерации выбираются K изображений с наибольшей неопределённостью.

Экспериментальная постановка: «gold $\rightarrow$ noisy $\rightarrow$ восстановление»

Имитация ухудшенной разметки (noisy masks)

Для оценки эффективности AL без привлечения дополнительной ручной разметки используется экспериментальная схема: часть эталонных (gold) масок искусственно ухудшается, формируя noisy-разметку, после чего проверяется, может ли итеративный AL-процесс приблизить качество модели к уровню обучения на gold-разметке. «Плохая» разметка создаётся за счёт уменьшения площади маски: gold-mask (0/1) сглаживается гауссовым фильтром и затем бинаризуется с повышенным порогом, после чего дополнительно применяется морфологическая эрозия.

Параметры генерации noisy: GaussianBlur(ksize=21), threshold=0.85, erode kernel=5 и iterations=2. Данная процедура приводит к систематическому уменьшению площади размеченной области и моделирует типичную ошибку разметки «недоразметка» (under-segmentation).

Обучение M_{noisy} и дообучение на смеси noisy+gold

На шаге M_{noisy_init} модель обучается на noisy-L0 в течение до 10 эпох с early stopping (patience=3) по метрике val_dice. На каждой итерации AL выполняется дообучение модели на смеси: L_{noisy} (noisy) и L_{gold} (gold), где gold-поднабор усиливается за счёт повторения (GOLD_REPEAT=3). Дообучение выполняется до 5 эпох с тем же правилом early stopping.

Результаты и анализ

Результаты по метрикам

По результатам одного запуска эксперимента получены следующие значения качества на валидационной выборке (val):

- Лучшая метрика Dice для модели `M_noisy_init`: 0.6445.
- После итераций Active Learning лучший результат Dice: 0.6614.
- Для сравнения: лучшая модель из предыдущего этапа работы (`best_segformer`) показала `Dice=0.6599` на val (оценка в совместимом окружении).

Таким образом, итеративный отбор наиболее неопределённых изображений из пула `U` и последующее дообучение на смеси `noisy+gold` позволили улучшить качество модели по сравнению с исходной `M_noisy_init` и приблизиться к уровню лучшей модели.

Контроль качества noisy-разметки

Для контроля степени искажения разметки сравнивается распределение доли площади маски (доля пикселей класса купероза) для `gold` и `noisy` масок.




Рисунок 1 — Распределение доли площади маски для `gold` и `noisy` разметки (train).




Рисунок 2 — Boxplot доли площади маски: сравнение gold и noisy.

Динамика качества по итерациям Active Learning

На рисунках ниже приведены: (1) кривая Dice на различных подвыборках в зависимости от номера итерации AL и (2) сравнение val Dice между baseline, M_noisy и итерациями AL.




Рисунок 3 — Качество (Dice) в зависимости от номера итерации Active Learning.




Рисунок 4 — Сравнение val Dice между baseline (best_segformer), M_noisy и итерациями AL.

Кривые обучения по эпохам

Для анализа процесса обучения построены графики изменения функции потерь и метрик на валидации по эпохам для этапа M_noisy_init и выбранной итерации AL.




Рисунок 5 — Динамика train/val loss на этапе M_noisy_init.




Рисунок 6 — Динамика val Dice/IoU на этапе M_noisy_init.




Рисунок 7 — Динамика train/val loss на итерации AL_iter_2.




Рисунок 8 — Динамика val Dice/IoU на итерации AL_iter_2.

Распределение uncertainty и визуальные примеры

На каждой итерации AL рассчитывается неопределённость на пуле U. Ниже приведены примеры распределения uncertainty на первой итерации, а также qualitative-анализ: сравнение предсказаний до и после дообучения на выбранных примерах.




Рисунок 9 — Гистограмма uncertainty на пуле U перед отбором (итерация 1).




Рисунок 10 — Boxplot uncertainty на пуле U (итерация 1).




Рисунок 11 — Qualitative-анализ: изображение, gold/noisy маски, pred_before и pred_after (итерация 1).

Заключение

В ходе практики реализован итеративный пайплайн Active Learning для задачи бинарной сегментации купероза. Показано, что при наличии ограниченного набора размеченных данных и пула «неразмеченных» изображений можно улучшать качество модели за счёт итеративного отбора наиболее неопределённых примеров и последующего дообучения. В экспериментальной постановке «gold $\rightarrow$ noisy $\rightarrow$ восстановление» активное обучение позволило повысить Dice на валидации по сравнению с обучением только на noisy-разметке и достигнуть уровня, сопоставимого с лучшей моделью предыдущего этапа.

Список использованных источников

1. PyTorch — официальный сайт фреймворка. URL: <https://pytorch.org/> (дата обращения: 09.06.2026).
2. Roboflow: платформа для подготовки датасетов и экспорта в форматы разметки (в т.ч. COCO). URL: <https://roboflow.com/> (дата обращения: 09.06.2026).
3. `pycocotools` Documentation / Repository. Работа с COCO-сегментацией (RLE/полигоны, декодирование масок).