



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра «Теоретическая информатика и компьютерные технологии»

ОТЧЕТ О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

Анализ моделей активного обучения для проблемы купероза

Исполнитель НИРС,

студент группы ИУ9 – 11М

(подпись, дата)

А.С. Ильичев

Руководитель НИРС

(подпись, дата)

М.О. Корлякова

Оглавление

Введение	3
Данные и разбиения	4
Обоснование использования активного обучения	5
Основные этапы работы	8
Результаты и анализ	15
Заключение	21
Список использованных источников.....	22

Введение

Тема данной работы — активное обучение (Active Learning) для сегментации купероза на изображениях лица.

Цель работы — показать эффективность Active Learning для задачи бинарной сегментации купероза, то есть продемонстрировать, что при итеративном отборе наиболее информативных изображений (например, по критерию неопределённости предсказаний модели) и последующем расширении обучающей выборки можно улучшать качество модели. В рамках работы реализуется цикл активного обучения: обучение модели на начальном наборе размеченных данных, оценка неопределённости на пуле неразмеченных изображений, выбор подмножества для уточнения разметки и повторное дообучение с последующей оценкой качества по метрикам сегментации.

Данные и разбиения

Описание набора данных

В работе используется датасет изображений лица с разметкой областей купероза (розацеа) в задаче бинарной сегментации. Данные организованы в виде четырёх частей:

- **train** — обучающая выборка (в текущей версии проекта содержит 305 изображений), используется для обучения моделей и проведения экспериментов с активным обучением.
- **val** — валидационная выборка, используется для подбора гиперпараметров, выбора лучшей эпохи и early stopping.
- **test_rf** — тестовая выборка из источника Roboflow, используется только для итоговой оценки качества на домене Roboflow.
- **test_cvat** — тестовая выборка из источника CVAT, также не участвует в обучении.

Каждая часть (train/val/test_rf/test_cvat) имеет одинаковую структуру:

- папка images/ с изображениями,
- файл аннотаций annotations.coco.

Формат аннотаций (COCO)

Разметка хранится в формате COCO Segmentation. В COCO-файле содержатся:

- список изображений (images) с полями id, file_name, width, height;
- список аннотаций (annotations), где каждая аннотация содержит image_id и описание области в поле segmentation.

Поле segmentation может быть задано:

- полигональной разметкой (список полигонов),
- либо **RLE-представлением** (run-length encoding).

В рамках бинарной сегментации купероза все полигоны/области для одного изображения объединяются в **одну бинарную маску** (0 — фон, 1 — купероз), которая затем приводится к размеру входа модели.

Обоснование применения активного обучения

Задача, рассматриваемая в данной работе, относится к области медицинского компьютерного зрения и формулируется как бинарная сегментация купероза на изображениях лица. Для каждого пикселя входного изображения модель должна определить, относится ли он к области проявления купероза или к фону. Результатом работы модели является бинарная маска, которая позволяет визуально и количественно оценивать площадь поражённой области.

Одной из ключевых проблем в задачах медицинской сегментации является высокая стоимость получения качественной разметки. В отличие от задач классификации, где аннотатору достаточно назначить изображению один класс, в задаче сегментации требуется размечать объект на уровне пикселей. Такая разметка занимает больше времени, требует аккуратности и, в идеальном случае, должна выполняться или проверяться специалистом. Для изображений кожи эта проблема особенно актуальна, поскольку границы области купероза могут быть нечёткими, цветовые переходы — плавными, а сама область поражения может занимать небольшую часть изображения.

При ограниченном объёме размеченных данных возникает задача рационального выбора изображений, которые следует размечать в первую очередь. Разметка всех доступных изображений может быть избыточной и трудоёмкой, тогда как случайный выбор новых примеров не всегда приводит к заметному улучшению качества модели. В связи с этим в работе используется подход активного обучения (Active Learning), цель которого — выбирать для разметки не произвольные изображения, а наиболее информативные с точки зрения модели.

Идея активного обучения заключается в том, что модель после первичного обучения анализирует пул неразмеченных изображений и оценивает степень собственной неопределённости. Затем для разметки выбираются изображения, на которых модель наименее уверена. Предполагается, что именно такие

примеры содержат больше новой информации для модели и после добавления их разметки в обучающую выборку могут дать больший прирост качества, чем случайно выбранные изображения.

Для задачи сегментации купероза такой подход является обоснованным по нескольким причинам.

Во-первых, в задаче присутствует выраженная неоднородность изображений. Снимки могут отличаться освещением, оттенком кожи, выраженностью покраснений, положением лица, качеством изображения и источником данных. В работе используются данные из разных источников, включая Roboflow и CVAT, что дополнительно создаёт проблему доменного сдвига. Поэтому модель может уверенно работать на одних типах изображений, но ошибаться на других. Active Learning позволяет выявлять именно те изображения, на которых модель испытывает наибольшие затруднения.

Во-вторых, область купероза не всегда имеет чёткие границы. В некоторых случаях переход между поражённой и непоражённой областью является плавным, что приводит к неопределённости в предсказании модели. Такие участки особенно важны для обучения, поскольку они помогают модели лучше различать реальные проявления купероза и похожие по цвету фоновые области кожи.

В-третьих, классы в задаче бинарной сегментации несбалансированы: большая часть пикселей изображения обычно относится к фону, а область купероза занимает меньшую долю. Из-за этого модель может переобучаться на фон или недооценивать небольшие области поражения. Отбор изображений с высокой неопределённостью позволяет чаще добавлять в обучение примеры, где модель затрудняется корректно выделить область интереса.

В-четвёртых, Active Learning позволяет имитировать практический сценарий работы с ограниченным бюджетом разметки. В реальном проекте невозможно

или нецелесообразно сразу размечать весь доступный массив изображений. Более рациональный подход состоит в том, чтобы сначала обучить модель на небольшом размеченном наборе, затем использовать её для отбора наиболее полезных новых изображений и постепенно улучшать качество модели. Такой процесс хорошо соответствует итеративной разработке систем компьютерного зрения.

Дополнительно в работе рассматривается экспериментальная постановка без привлечения новой ручной разметки. Для этого часть эталонных масок искусственно ухудшается: площадь маски уменьшается с помощью сглаживания, повышенного порога бинаризации и морфологической эрозии. Такая noisy-разметка имитирует ситуацию, когда начальная разметка является неполной или неточной. Далее проверяется, может ли активное обучение за счёт итеративного добавления изображений с корректной gold-разметкой улучшить качество модели и приблизить её к уровню модели, обученной на более качественных данных.

Таким образом, использование Active Learning в данной задаче позволяет решить сразу несколько практических проблем: снизить потребность в полной ручной разметке, сфокусировать внимание на наиболее сложных изображениях, повысить эффективность дообучения модели и построить воспроизводимый экспериментальный процесс улучшения качества сегментации. Для задачи сегментации купероза, где разметка является трудоёмкой, а границы объекта часто неоднозначны, активное обучение является обоснованным и практически полезным подходом.

Основные этапы работы

В рамках НИР была реализована программная система для проведения эксперимента с активным обучением в задаче бинарной сегментации купероза. Работа включает несколько последовательных этапов: подготовку данных, формирование зашумлённой разметки, обучение начальной модели,

итеративный отбор наиболее информативных изображений, дообучение модели и анализ результатов.

1. Подготовка окружения и конфигурации эксперимента

На первом этапе задаются основные параметры эксперимента: пути к данным, директория для сохранения результатов, параметры модели, обучения и активного обучения. Датасет хранится в директории `dataset`, а результаты работы программы сохраняются в папку `al_noisy_outputs`.

В конфигурации указываются следующие основные параметры:

`IMAGE_SIZE = 256` — размер, к которому приводятся входные изображения и маски;

`TRAIN_BATCH_SIZE = 2` — размер батча при обучении;

`ACCUM_STEPS = 2` — число шагов аккумуляции градиента, что позволяет получить эффективный `batch size` около 4;

`NOISY_EPOCHS = 10` — максимальное число эпох для начального обучения модели на `noisy`-разметке;

`FINE_TUNE_EPOCHS = 5` — максимальное число эпох дообучения на каждой итерации Active Learning;

`EARLY_STOP_PATIENCE = 3` — параметр `early stopping`;

`L_FRAC = 0.30` — доля обучающей выборки, попадающая в начальный размеченный набор `L0`;

`AL_ITERS = 3` — число итераций Active Learning;

`K_PER_ITER = 20` — число изображений, выбираемых из пула `U` на каждой итерации.

Для обеспечения воспроизводимости фиксируется значение `SEED = 0`. Это позволяет получать одинаковое разбиение `train`-выборки на `L0` и `U0` при повторных запусках программы.

2. Загрузка данных и обработка COCO-разметки

В работе используется структура данных, состоящая из четырёх частей:

`train` — обучающая выборка;

`val` — валидационная выборка;

`test_rf` — тестовая выборка из источника Roboflow;

`test_cvat` — тестовая выборка из источника CVAT.

Каждый `split` содержит папку `images` с изображениями и файл аннотаций в формате COCO. В программе реализован поиск COCO-файла с учётом нескольких возможных вариантов имени: `annotations.coco.json`, `_annotations.coco.json`, `annotations.coco`, `_annotations.coco`.

После загрузки COCO-файла строится индекс изображений и аннотаций. Для каждого изображения по его `image_id` извлекаются связанные аннотации. Поле `segmentation` преобразуется в бинарную маску. Если разметка представлена полигонами, они преобразуются в RLE-представление средствами `pycocotools`, после чего декодируются в маску. Если разметка уже хранится в RLE-формате, она декодируется напрямую.

Так как задача является бинарной сегментацией, все области купероза для одного изображения объединяются в одну маску: пиксели объекта получают значение 1, пиксели фона — 0.

3. Предобработка изображений и масок

Перед подачей в модель изображения приводятся к единому размеру 256×256 , нормализуются и переводятся в формат тензора PyTorch. Для изображений используется нормализация по среднему и стандартному отклонению ImageNet:

```
mean = (0.485, 0.456, 0.406);
```

```
std = (0.229, 0.224, 0.225).
```

Маски также приводятся к размеру 256×256 , но для них используется интерполяция ближайшего соседа, чтобы не исказить бинарные значения классов. В результате для каждого изображения формируется пара: входной тензор изображения и соответствующая бинарная маска.

4. Формирование noisy-разметки

Для имитации неидеальной разметки реализуется процедура искусственного ухудшения `gold`-масок. Основная идея состоит в уменьшении площади

размеченной области, то есть в моделировании ситуации, когда аннотация покрывает не всю область купероза.

Для этого к исходной бинарной маске применяется следующая последовательность операций:

Маска переводится в формат `float32`.

К маске применяется гауссово размытие с размером ядра `NOISY_BLUR_KSIZE = 21`.

После размытия выполняется бинаризация с повышенным порогом `NOISY_THR = 0.85`.

Дополнительно применяется морфологическая эрозия с ядром 5×5 и числом итераций 2.

Такая процедура приводит к уменьшению площади положительного класса. Полученные `noisy`-маски используются как имитация плохой или неполной разметки. Это позволяет провести эксперимент без привлечения новой ручной аннотации и проверить, может ли Active Learning улучшить качество модели при постепенном добавлении более качественных `gold`-масок.

5. Инициализация модели сегментации

В качестве модели используется SegFormer для задачи семантической сегментации. В программе реализован класс-обёртка `SegFormerBinary`, который адаптирует модель к бинарной сегментации, то есть к предсказанию одного канала выходной маски.

Модель инициализируется чекпойнтом:

```
nvidia/segformer-b5-finetuned-ade-640-640
```

При загрузке модели задаётся `num_labels = 1`, так как в задаче требуется предсказывать только один класс — область купероза. На выходе модель формирует карту логитов, которая при необходимости интерполируется до размера входного изображения. Для получения вероятностей используется функция `sigmoid`, а для получения бинарной маски применяется порог 0.5.

6. Разбиение обучающей выборки на L_0 и U_0

После загрузки обучающей выборки список идентификаторов изображений перемешивается с фиксированным `seed`. Далее выборка делится на две части:

L_0 — начальный размеченный набор;

U_0 — пул изображений, которые считаются неразмеченными до момента отбора.

В реализованной схеме L_0 составляет примерно 30% от `train`-выборки, а оставшиеся 70% формируют пул U_0 . При этом `gold`-разметка для изображений из U_0 считается скрытой. Она используется только после того, как изображение было выбрано алгоритмом `Active Learning`.

Такой подход имитирует реальный сценарий, в котором имеется небольшой начальный набор размеченных данных и большой пул изображений, ожидающих разметки.

7. Обучение начальной модели M_{noisy}

На следующем этапе обучается начальная модель `M_noisy_init`. Она обучается только на наборе L_0 , причём вместо исходных `gold`-масок используются `noisy`-маски, полученные процедурой искусственного уменьшения площади разметки. Для оптимизации применяется `AdamW` с функцией потерь, состоящей из двух компонентов:

```
binary cross entropy with logits;
```

```
soft Dice loss.
```

Такое сочетание функции потерь позволяет учитывать как попиксельную ошибку классификации, так и качество перекрытия предсказанной и эталонной масок. Это особенно важно для задачи сегментации, где площадь положительного класса может быть существенно меньше площади фона.

Во время обучения применяется `early stopping` по метрике `val_dice`. Это позволяет сохранить лучшее состояние модели и остановить обучение, если качество на валидационной выборке перестаёт улучшаться.

8. Расчёт неопределённости модели

После обучения начальной модели выполняется оценка неопределённости на изображениях из пула U . Для каждого изображения модель строит вероятностную карту сегментации. Затем считается доля уверенных пикселей.

Пиксель считается уверенным, если выполняется одно из условий:

вероятность положительного класса $p \geq 0.90$;

вероятность положительного класса $p \leq 0.10$.

Иными словами, модель уверена либо в принадлежности пикселя к области купероза, либо в принадлежности пикселя к фону. Все пиксели с вероятностью между 0.10 и 0.90 считаются менее уверенными.

Для изображения вычисляется показатель:

$uncertainty = 1 - confident_ratio$

где $confident_ratio$ — доля уверенных пикселей. Чем выше значение $uncertainty$, тем менее уверенно модель предсказывает маску для данного изображения. Такие изображения считаются более информативными для дальнейшей разметки и дообучения.

9. Итеративный цикл Active Learning

Основная часть работы представляет собой итеративный цикл Active Learning.

На каждой итерации выполняются следующие действия:

Для всех изображений из текущего пула U вычисляется $uncertainty$.

Из пула выбираются $K = 20$ изображений с максимальным значением $uncertainty$.

Для выбранных изображений раскрывается gold-разметка.

Эти изображения удаляются из пула U и добавляются в набор L_gold .

Модель дообучается на смеси:

L_noisy — начальный набор с noisy-разметкой;

L_gold — выбранные изображения с gold-разметкой.

Для усиления вклада качественной gold-разметки используется повторение gold-поднабора ($GOLD_REPEAT = 3$). Это позволяет модели сильнее учитывать новые корректные примеры, которые были выбраны на итерациях Active Learning.

После каждой итерации модель оценивается на `val`, `test_rf` и `test_cvat`. Результаты сохраняются в общую структуру `results`, что позволяет затем анализировать динамику качества по итерациям.

10. Оценка качества модели

Качество модели оценивается с использованием метрик Dice и IoU. Dice показывает степень совпадения предсказанной маски с эталонной и является одной из основных метрик в задачах медицинской сегментации. IoU дополнительно оценивает отношение площади пересечения масок к площади их объединения.

Для каждого `split` рассчитываются:

- среднее значение Dice;
- стандартное отклонение Dice;
- среднее значение IoU;
- стандартное отклонение IoU;
- количество изображений.

Оценка выполняется отдельно на `val`, `test_rf` и `test_cvat`, что позволяет анализировать не только качество на валидационной выборке, но и переносимость модели на разные источники данных.

11. Сохранение результатов и визуализация

После завершения эксперимента результаты сохраняются в файл:

`al_noisy_outputs/results.json`

В этот файл записываются:

- параметры эксперимента;
- размер начального набора `L0` и пула `U0`;
- список выбранных изображений на каждой итерации;
- значения `uncertainty`;
- метрики качества по итерациям;
- история обучения по эпохам.

Дополнительно программа строит набор графиков, которые сохраняются в директорию:

```
al_noisy_outputs/plots
```

К основным графикам относятся:

кривая Dice по итерациям Active Learning;

сравнение качества `best_segformer`, `M_noisy` и моделей после AL-итераций;

графики train/val loss по эпохам;

графики val Dice и val IoU по эпохам;

распределения uncertainty;

гистограмма и boxplot доли площади маски для gold и noisy-разметки.

Также сохраняется качественная визуализация для первой итерации Active Learning. На ней для выбранных изображений сравниваются исходное изображение, gold-маска, noisy-маска, предсказание модели до дообучения и предсказание после дообучения.

12. Итоговая логика эксперимента

В результате реализован полный pipeline для проверки применимости Active Learning к задаче сегментации купероза. Эксперимент начинается с обучения модели на ограниченном наборе данных с искусственно ухудшенной разметкой. Затем модель самостоятельно определяет наиболее сложные изображения из пула $\mathcal{U}$ по уровню неопределённости. После добавления gold-разметки для выбранных изображений модель дообучается, а качество оценивается на фиксированных валидационных и тестовых выборках.

Такая схема позволяет проверить, даёт ли целенаправленный отбор наиболее информативных изображений прирост качества по сравнению с исходной моделью, обученной только на noisy-разметке. Кроме того, реализованный pipeline можно адаптировать к реальному сценарию, где вместо автоматического раскрытия gold-маски выбранные изображения передаются аннотатору для ручной разметки.

Результаты и анализ

Результаты по метрикам

По результатам одного запуска эксперимента получены следующие значения качества на валидационной выборке (val):

- Лучшая метрика Dice для модели M_noisy_init: 0.6445.
- После итераций Active Learning лучший результат Dice: 0.6614.
- Для сравнения: лучшая модель из предыдущего этапа работы (best_segformer) показала Dice=0.6599 на val (оценка в совместимом окружении).

Таким образом, итеративный отбор наиболее неопределённых изображений из пула U и последующее дообучение на смеси noisy+gold позволили улучшить качество модели по сравнению с исходной M_noisy_init и приблизиться к уровню лучшей модели.

Контроль качества noisy-разметки

Для контроля степени искажения разметки сравнивается распределение доли площади маски (доля пикселей класса купероза) для gold и noisy масок.




Рисунок 1 — Распределение доли площади маски для gold и noisy разметки (train).




Рисунок 2 — Boxplot доли площади маски: сравнение gold и noisy.

Динамика качества по итерациям Active Learning

На рисунках ниже приведены: (1) кривая Dice на различных подвыборках в зависимости от номера итерации AL и (2) сравнение val Dice между baseline, M_noisy и итерациями AL.




Рисунок 3 — Качество (Dice) в зависимости от номера итерации Active Learning.




Рисунок 4 — Сравнение val Dice между baseline (best_segformer), M_noisy и итерациями AL.

Кривые обучения по эпохам

Для анализа процесса обучения построены графики изменения функции потерь и метрик на валидации по эпохам для этапа M_noisy_init и выбранной итерации AL.




Рисунок 5 — Динамика train/val loss на этапе M_noisy_init.




Рисунок 6 — Динамика val Dice/IoU на этапе M_noisy_init.




Рисунок 7 — Динамика train/val loss на итерации AL_iter_2.




Рисунок 8 — Динамика val Dice/IoU на итерации AL_iter_2.

Распределение uncertainty и визуальные примеры

На каждой итерации AL рассчитывается неопределённость на пуле U. Ниже приведены примеры распределения uncertainty на первой итерации, а также qualitative-анализ: сравнение предсказаний до и после дообучения на выбранных примерах.




Рисунок 9 — Гистограмма uncertainty на пуле U перед отбором (итерация 1).




Рисунок 10 — Boxplot uncertainty на пуле U (итерация 1).



Рисунок 11 — Qualitative-анализ: изображение, gold/noisy маски, pred_before и pred_after (итерация 1).

Заключение

В ходе практики реализован итеративный пайплайн Active Learning для задачи бинарной сегментации купероза. Показано, что при наличии ограниченного набора размеченных данных и пула «неразмеченных» изображений можно улучшать качество модели за счёт итеративного отбора наиболее неопределённых примеров и последующего дообучения. В экспериментальной постановке «gold → noisy → восстановление» активное обучение позволило повысить Dice на валидации по сравнению с обучением только на noisy-разметке и достигнуть уровня, сопоставимого с лучшей моделью предыдущего этапа.

Список использованных источников

1. PyTorch — официальный сайт фреймворка. URL: <https://pytorch.org/> (дата обращения: 09.06.2026).
2. Roboflow: платформа для подготовки датасетов и экспорта в форматы разметки (в т.ч. COCO). URL: <https://roboflow.com/> (дата обращения: 09.06.2026).
3. `pycocotools` Documentation / Repository. Работа с COCO-сегментацией (RLE/полигоны, декодирование масок).